1. **Практическая часть: Обучение и анализ.**

   На корпусе новостей “Московского комсомольца” были обучены модели CBOW и Skip-Gram с negative sampling.

   <u>Этапы обучения</u>:

   - Загрузка и подготовка данных
     - для ускорения обучения тренировочная выборка была урезана до 10000 документов, проверочная – до 2000
   - Предобработка текстов
     - токенизация,
     - нормализация,
     - удаление стоп-слов
   - Векторизация
   - Обучение CBOW с параметрами:
     - размер контекстного окна – 2,
     - размер эмбеддингов – 100,
     - количество эпох – 2,
     - learning rate – 0.001,
     - ограничение по количеству батчей – 500,
     - размер батча – 256,
     - количество обучающих примеров – 960716.
   - Обучение Skip-Gram с параметрами:
     - размер контекстного окна – 2,
     - количество негативных примеров на один позитивный – 5,
     - размер эмбеддингов – 100,
     - количество эпох – 1,
     - learning rate – 0.001,
     - ограничение по количеству батчей – 300,
     - размер батча – 512,
     - урезанный датасет (первые 1000 документов) – 402248 пар.
   - Анализ и визуализация эмбеддингов

   По итогам обучения были достигнуты следующие значения ошибки:

   CBOW: `Epoch 2, Train Loss: 5.8455, Val Loss: 5.2701`

   Skip-Gram: `Epoch 1, Loss: 0.8455`

   Для визуализации с PCA были выбраны CBOW-эмбеддинги 16 слов, составляющих 4 тематические группы (“транспорт”, “Москва/власть”, “спорт”, “кино”):

   `['автомобиль', 'водитель', 'транспорт', 'авария',`

```
'москва', 'собянин', 'столица', 'кремль',
'олимпиада', 'спорт', 'чемпионат', 'матч',
'кино', 'фильм', 'зритель', 'оскар']
```

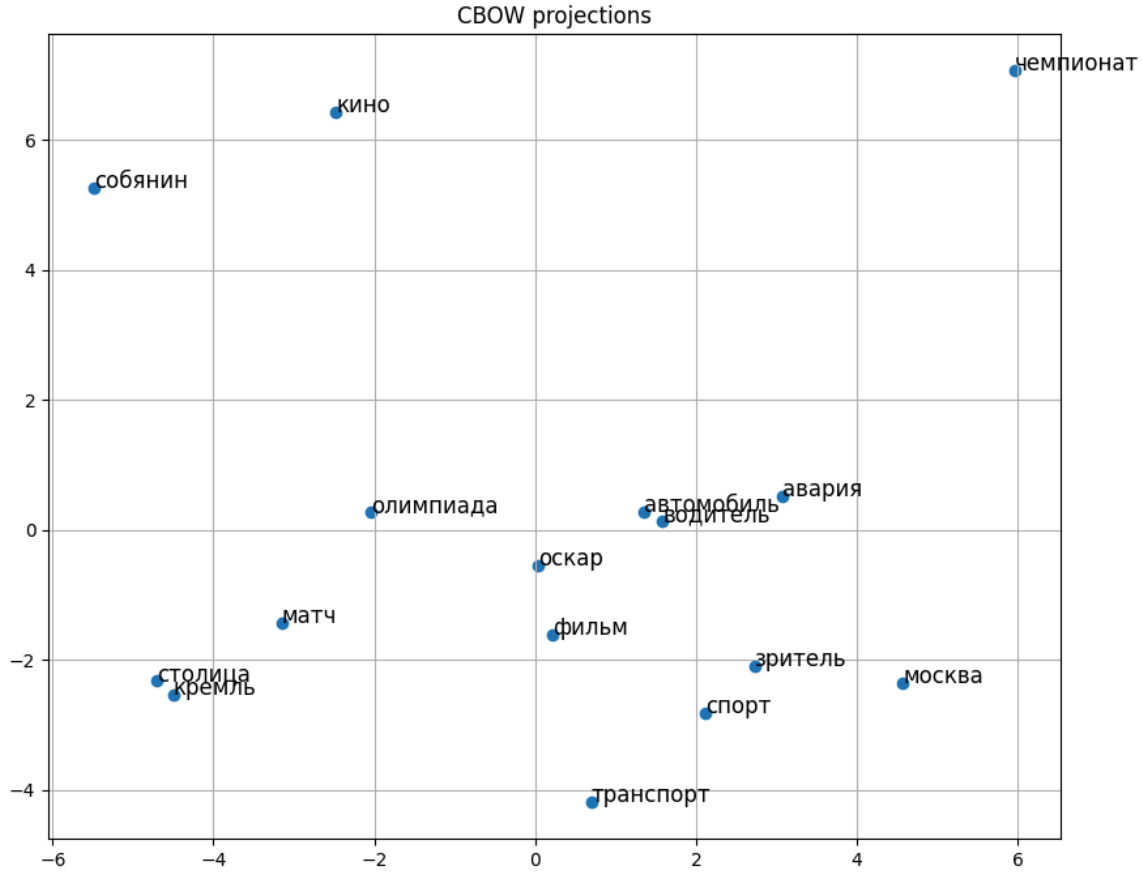

Слова по темам лишь частично объединяются в кластеры на визуализации:

а) Можно выделить кластер слов транспортной тематики: точки векторов “автомобиль”, “водитель” и “авария” находятся максимально близко, в то время как “транспорт” удален от группы – он ближе к вектору слова “спорт” (морфологическая и синтаксическая близость перевешивает тематическую).

б) Из лексем, относящихся к спортивной тематике, в одной области находятся “матч” и “олимпиада”, а вектор “чемпионат” расположен на наибольшем расстоянии от всех точек, что довольно труднообъяснимо, ведь, к примеру, чемпионат Европы по футболу 2020 был так же перенесен на 2021, как и олимпийские игры. Возможно, у слова “чемпионат” более широкий контекст употребления (напр. чемпионат по шахматам, биатлону, плаванию).

в) Из слов темы “Москва/власть” особенно близко расположены “столица” и “Кремль”, в то время как “Москва” и “Собянин” сильно смещены вверх и вправо

соответственно. Можно предположить, что имена собственные отличаются по контекстам упоминаний в новостях от более функциональных “столицы” и “Кремля”: Москва – конкретный топоним (место, где происходят события), Собянин – политический деятель (принимает решения, действует).

г) Точки слов, относящихся к тематике кино, тоже плохо группируются: можно выделить в одну группу "фильм", "Оскар", "зритель" (хотя тогда в кластер попадает “спорт” и очень близко находятся слова тематики “транспорт”), в то время как точка "кино" (более широкое понятие, кино как индустрия) отдалена и расположена ближе к точке “Собянин” – возможно, они встречались вместе в контексте ковидных ограничений, закрытия кинотеатров и мер поддержки в Москве.

2. **Аналитическая часть: Эксперимент с гиперпараметрами.**

Эксперимент с изменением размера окна и размерности эмбеддинга был проведен с моделью Skip-Gram. В качестве тестовых слов были выбраны “карантин”, “самоизоляция”, “удаленный”, “закрытие”.

Результаты представлены в таблице (+ аутпут с визуализациями в конце документа):

window size	embedding size	average cosine similarity	loss	data (pairs)
1	50	-0.0201	0.8872	202124
1	100	0.0626	0.8474	202124
1	200	-0.0166	0.8258	202124
3	50	-0.0075	0.8702	600372
3	100	0.1158	0.8416	600372
3	200	-0.0066	0.8194	600372
5	50	0.0712	0.8637	990620
5	100	0.0756	0.8384	990620
5	200	0.0196	0.8132	990620

1) Влияние размера контекстного окна

- **Window size = 1**: модель видит только непосредственно соседние слова, что подходит для выявления синтаксических зависимостей, но не тематической близости. Среднее косинусное сходство на тестовом наборе слов очень низкое (от -0,02 до 0,06).
- **Window size = 3**: достигается наилучший результат при размерности эмбеддингов = 100 (самое высокое значение сходства – 0,116), однако при размерностях 50 и 200 значения низкие. Можно назвать оптимальным размером окна для выявления тематической близости.
- **Window size = 5**: стабильно положительные результаты для всех размерностей (0,07, 0,075, 0,019), но немного ниже, чем пик при размере окна = 3. Возможно, в большое окно попадает больше шума, что снижает точность группировки по тематике.

2) Влияние размерности эмбеддинга

- **Размерность = 50**: результаты по сходству в основном отрицательные или очень низкие (лучший – 0,0712 при window size = 5). У модели как бы недостаточно пространства, чтобы уловить сложные семантические связи.
- **Размерность = 100**: стабильно лучшие результаты при всех размерах окна (0,0626, 0,1158, 0,0756) – оптимальная размерность на данном объеме данных.
- **Размерность = 200**: результаты отрицательные или близкие к нулю – можно предположить, что модель переобучается и начинает запоминать шум и специфику обучающих данных (значения ошибки снижаются с повышением размерности эмбеддингов при фиксированном размере окна).

3) Влияние гиперпараметров на скорость обучения

- Увеличение размера контекстного окна линейно увеличивает количество обучающих пар, что напрямую влияет время обучения – модель обучается дольше.
- Повышение размерности эмбеддингов так же замедляет обучения, так как требует больше вычислительных ресурсов.

Вывод:

Для тематически близких слов лучше всего подходит размер окна – 3 (максимальное значение среднего сходства при комбинации window size=3, embedding size=100). Окно размера 5 тоже работает, но немного хуже (предположительно из-за шума).

Для синтаксически близких слов лучше подходит маленькое окно – 1 (модель предсказывает только непосредственно соседей слова, что помогает улавливать грамматические паттерны). В эксперименте при размере окна = 1 в среднем самые низкие значения сходства между набором слов, объединенных тематически, следовательно, можно предположить, что модель фокусируется на других видах связей.

Также отметим, что эксперимент имеет такие ограничения, как малый объем набора значений гиперпараметров, субъективный выбор тестовых слов, урезанный набор обучающих данных, поэтому наблюдения нуждаются в дополнительной валидации.

Вывод с визуализациями векторов при обучении моделей:

Гиперпараметры Skim-Gram: window size = 1, embedding size = 50
Урезанный датасет для Skip-Gram: 202124 пар
Epoch 1, Loss: 0.8872

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']:
-0.0201

Визуализация эмбеддингов:

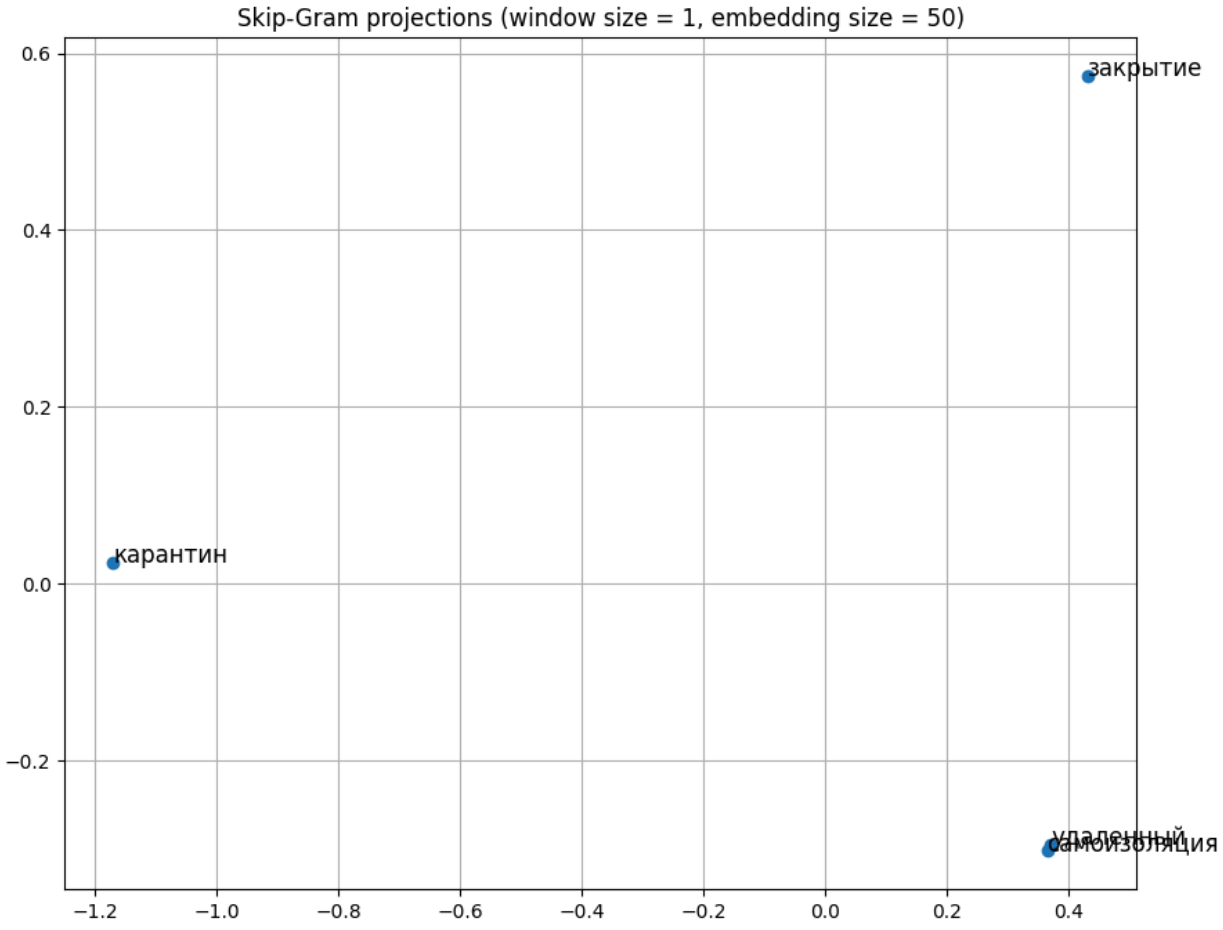

Гиперпараметры Skim-Gram: window size = 1, embedding size = 100
Урезанный датасет для Skip-Gram: 202124 пар
Epoch 1, Loss: 0.8474

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']: 0.0626

Визуализация эмбеддингов:

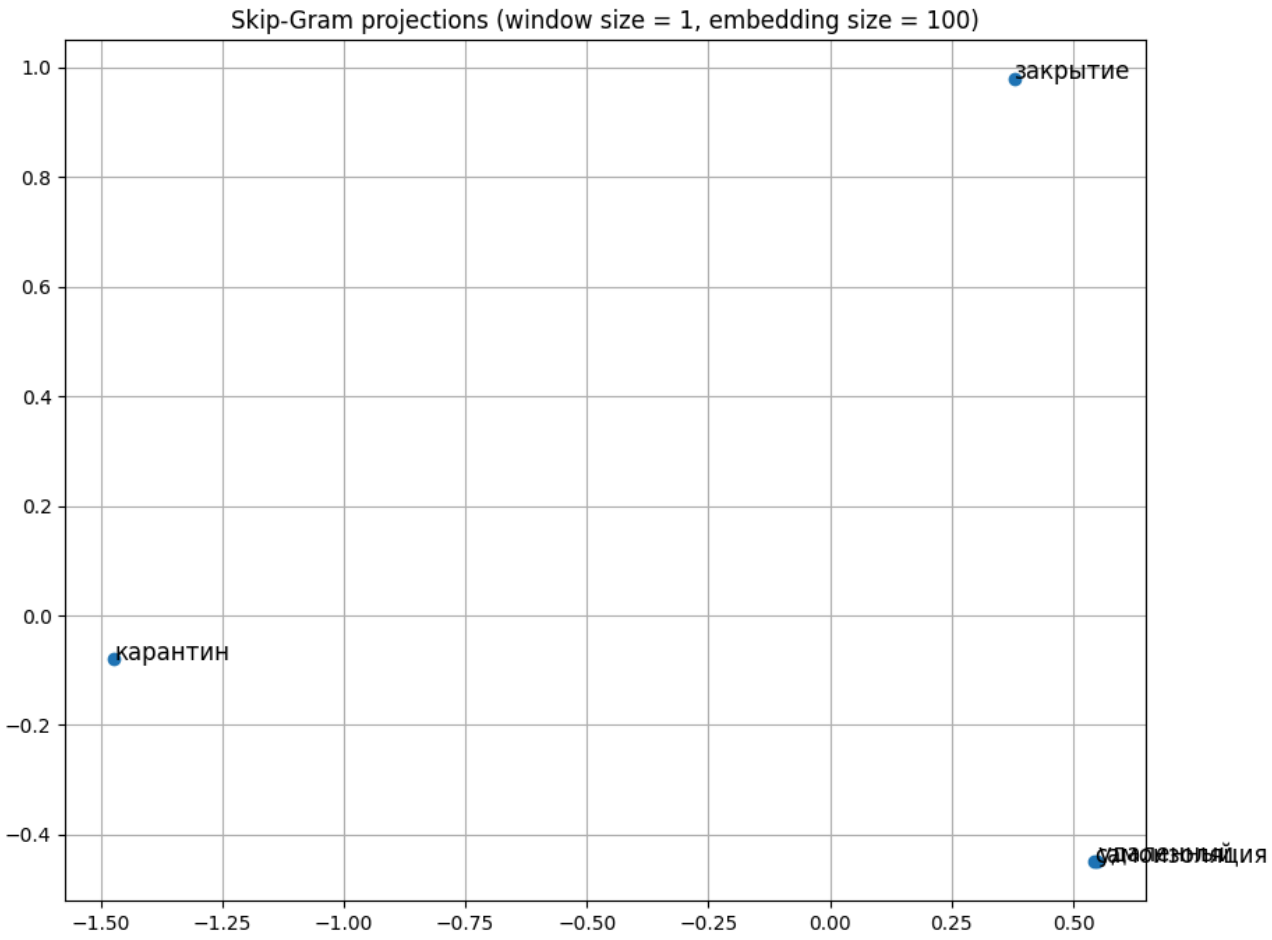

Гиперпараметры Skim-Gram: window size = 1, embedding size = 200
Урезанный датасет для Skip-Gram: 202124 пар
Epoch 1, Loss: 0.8258

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']: -0.0166

Визуализация эмбеддингов:

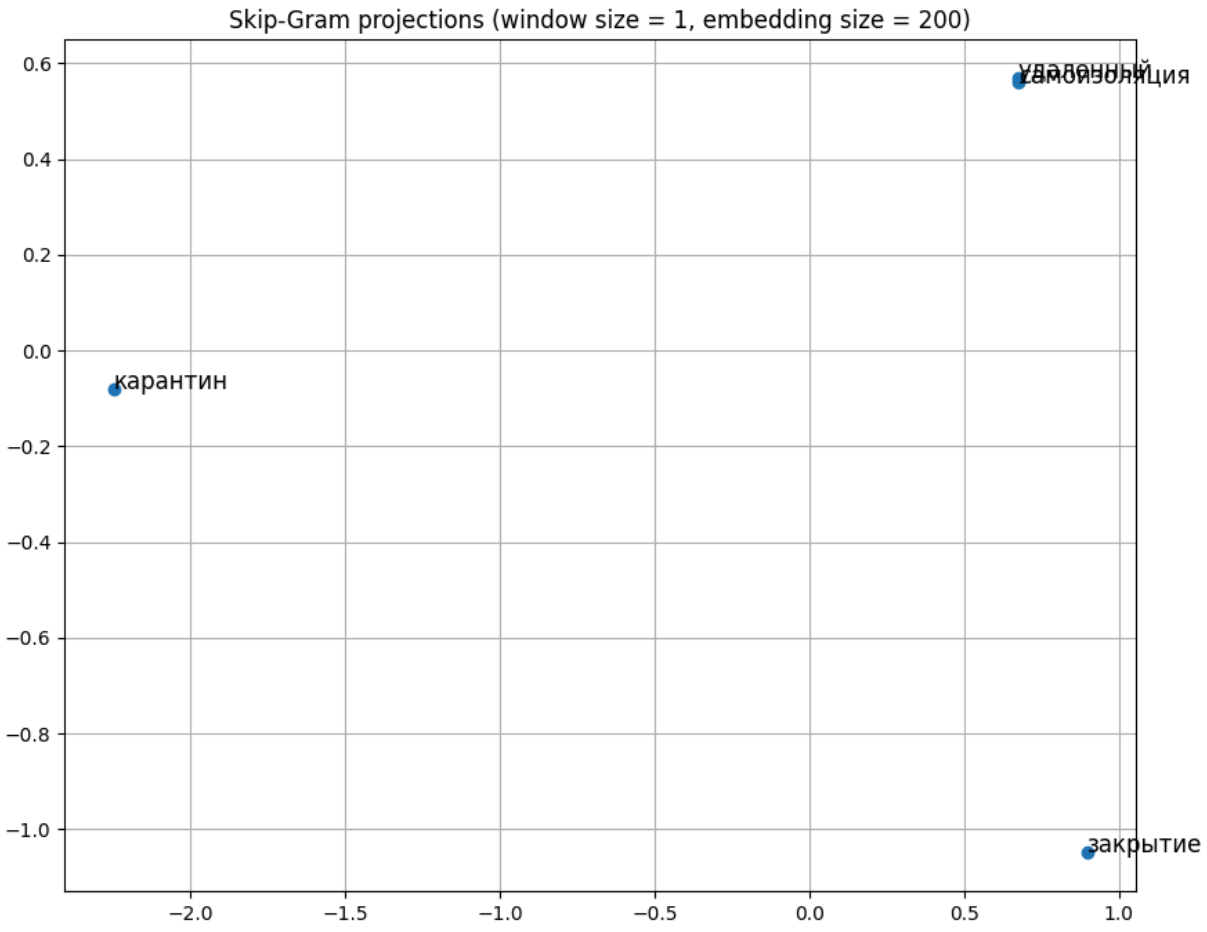

Гиперпараметры Skim-Gram: window size = 3, embedding size = 50
Урезанный датасет для Skip-Gram: 600372 пар
Epoch 1, Loss: 0.8702

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']: -0.0075

Визуализация эмбеддингов:

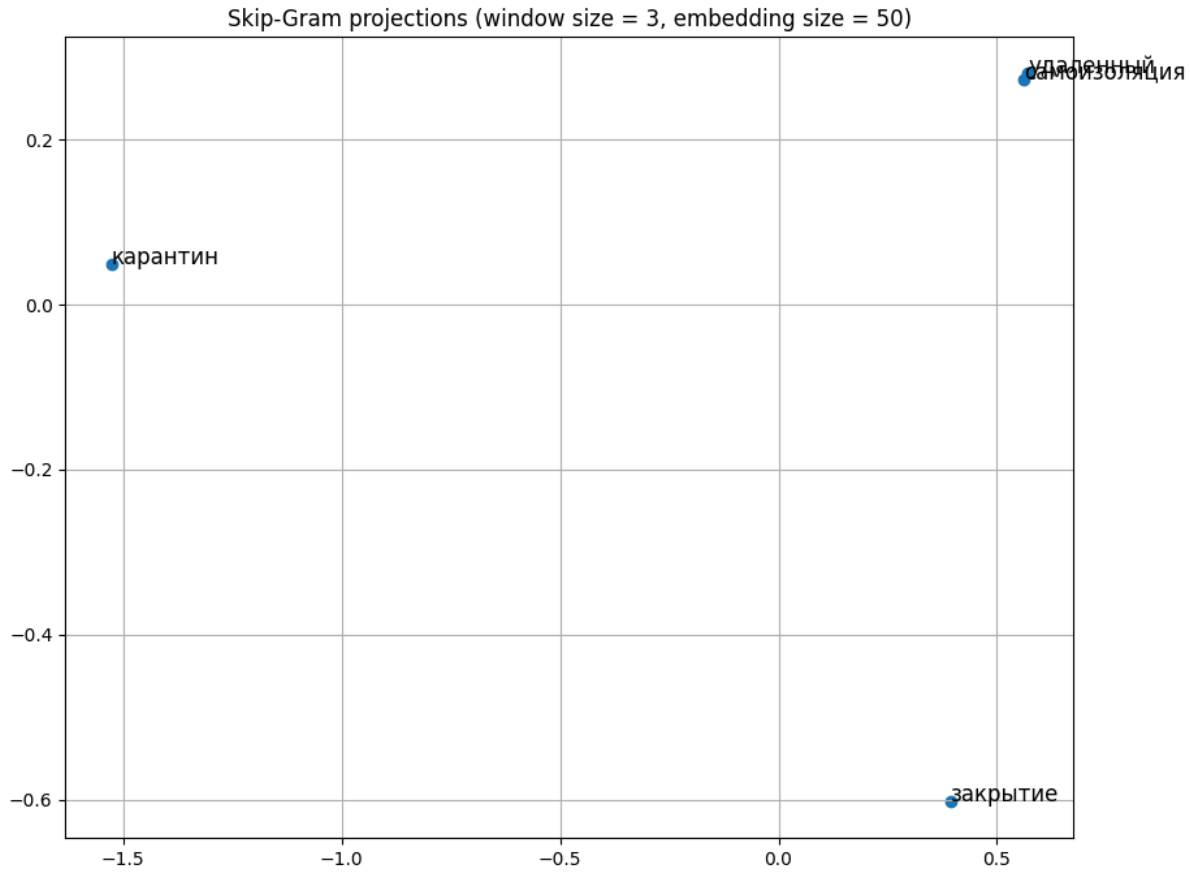

Гиперпараметры Skim-Gram: window size = 3, embedding size = 100
Урезанный датасет для Skip-Gram: 600372 пар
Epoch 1, Loss: 0.8416

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']:
0.1158

Визуализация эмбеддингов:

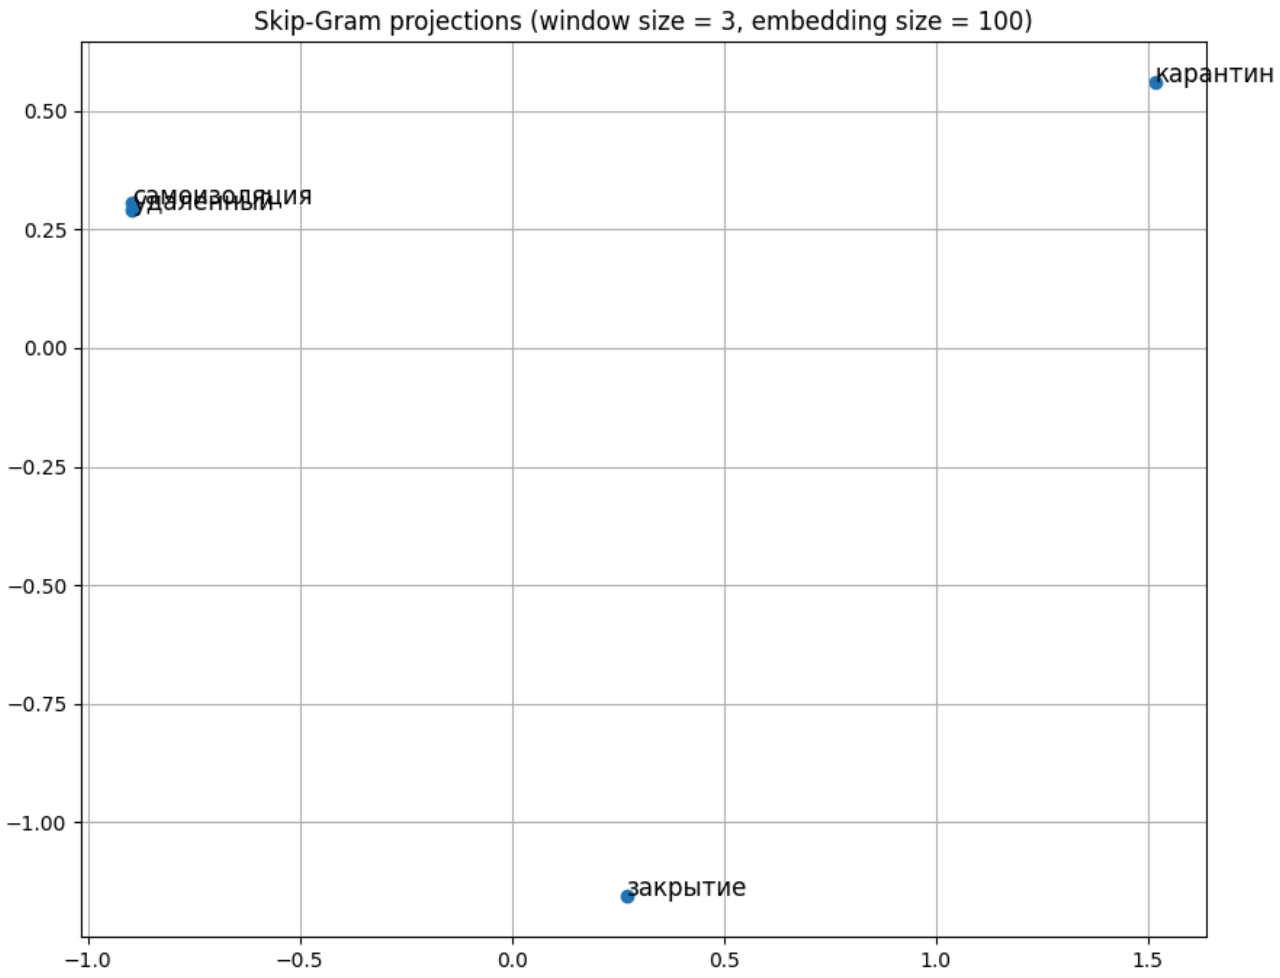

Гиперпараметры Skim-Gram: window size = 3, embedding size = 200
Урезанный датасет для Skip-Gram: 600372 пар
Epoch 1, Loss: 0.8194

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']: -0.0066

Визуализация эмбеддингов:

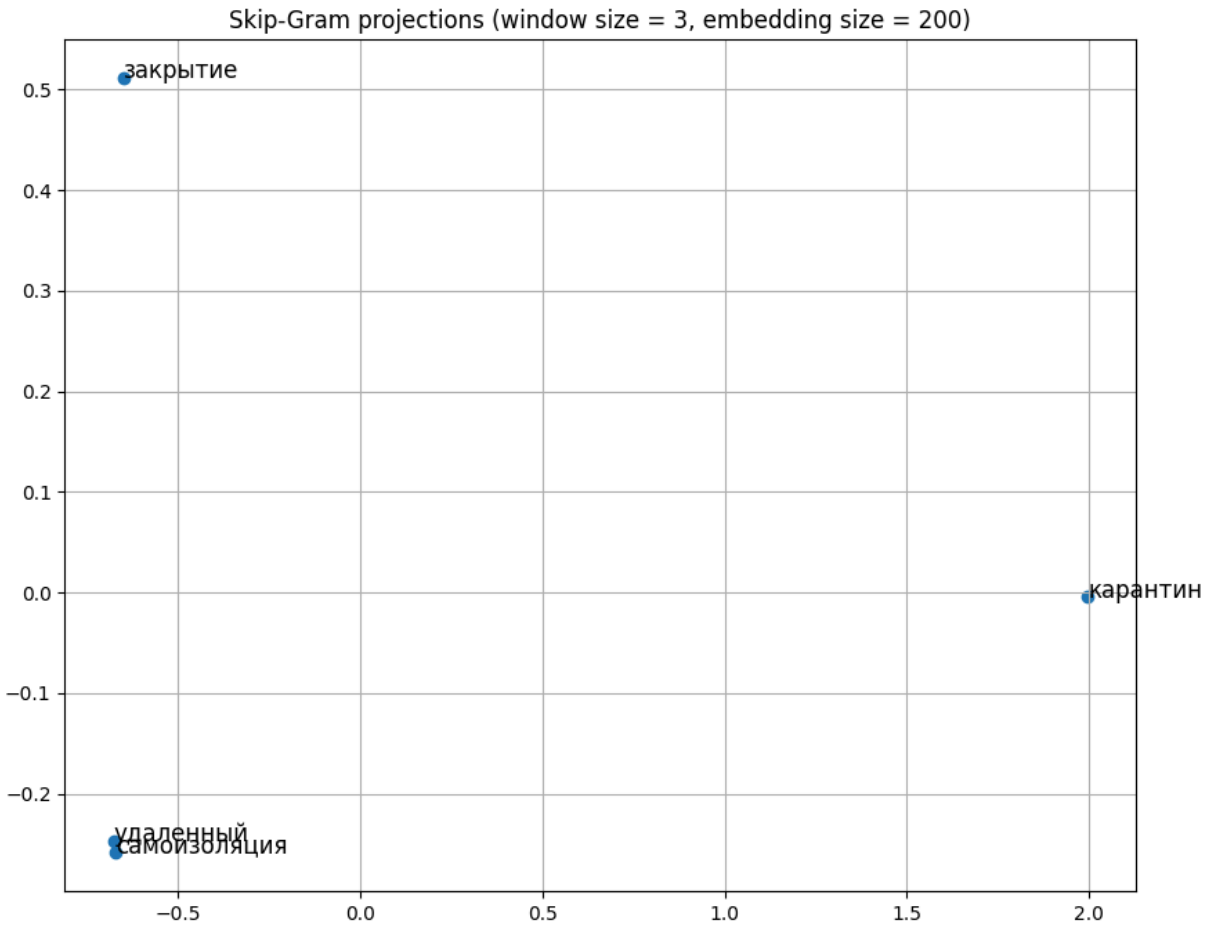

Гиперпараметры Skim-Gram: window size = 5, embedding size = 50
Урезанный датасет для Skip-Gram: 990620 пар
Epoch 1, Loss: 0.8637

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']: 0.0712

Визуализация эмбеддингов:

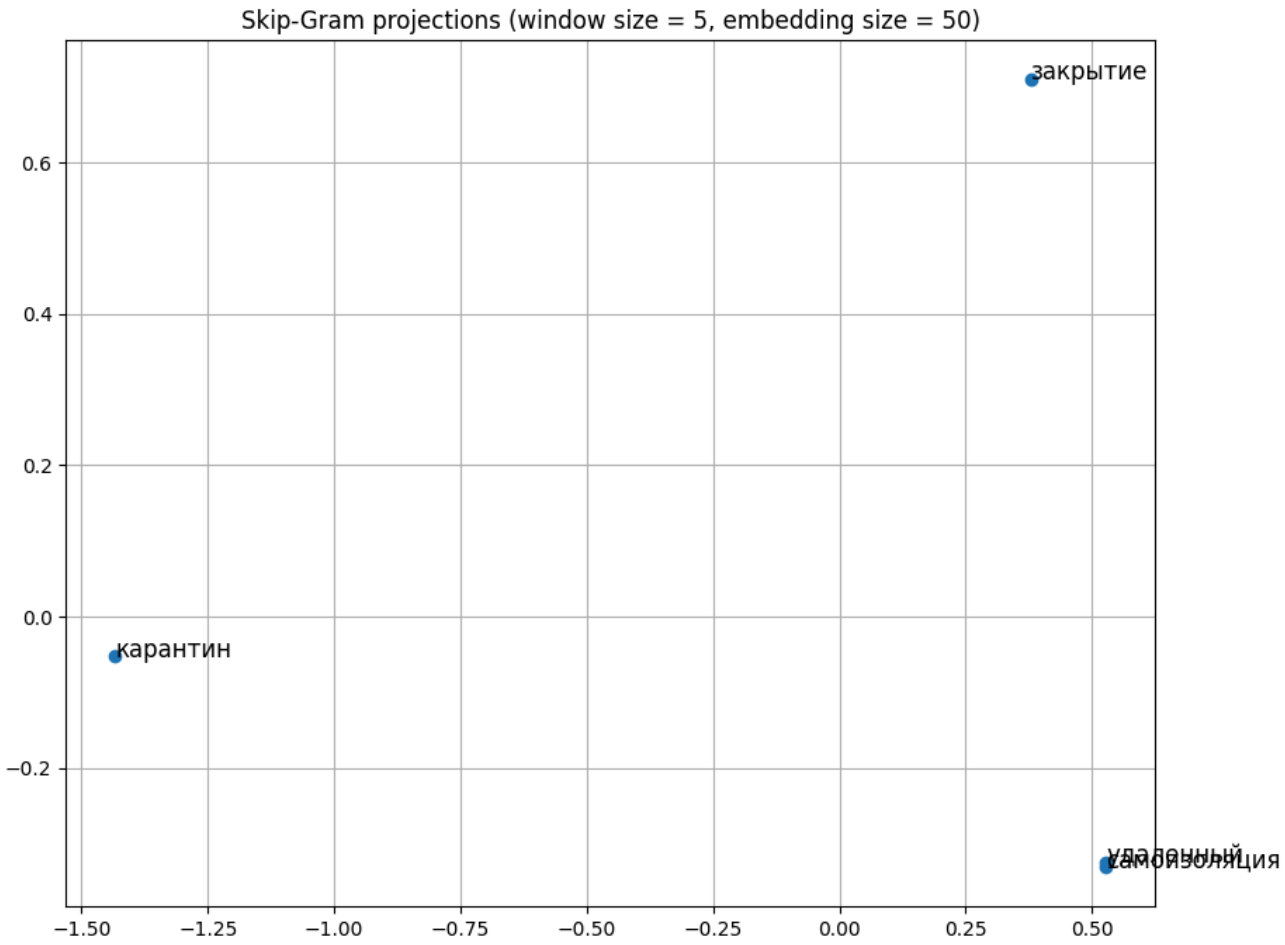

Гиперпараметры Skim-Gram: window size = 5, embedding size = 100
Урезанный датасет для Skip-Gram: 990620 пар
Epoch 1, Loss: 0.8384

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']:
0.0756

Визуализация эмбеддингов:

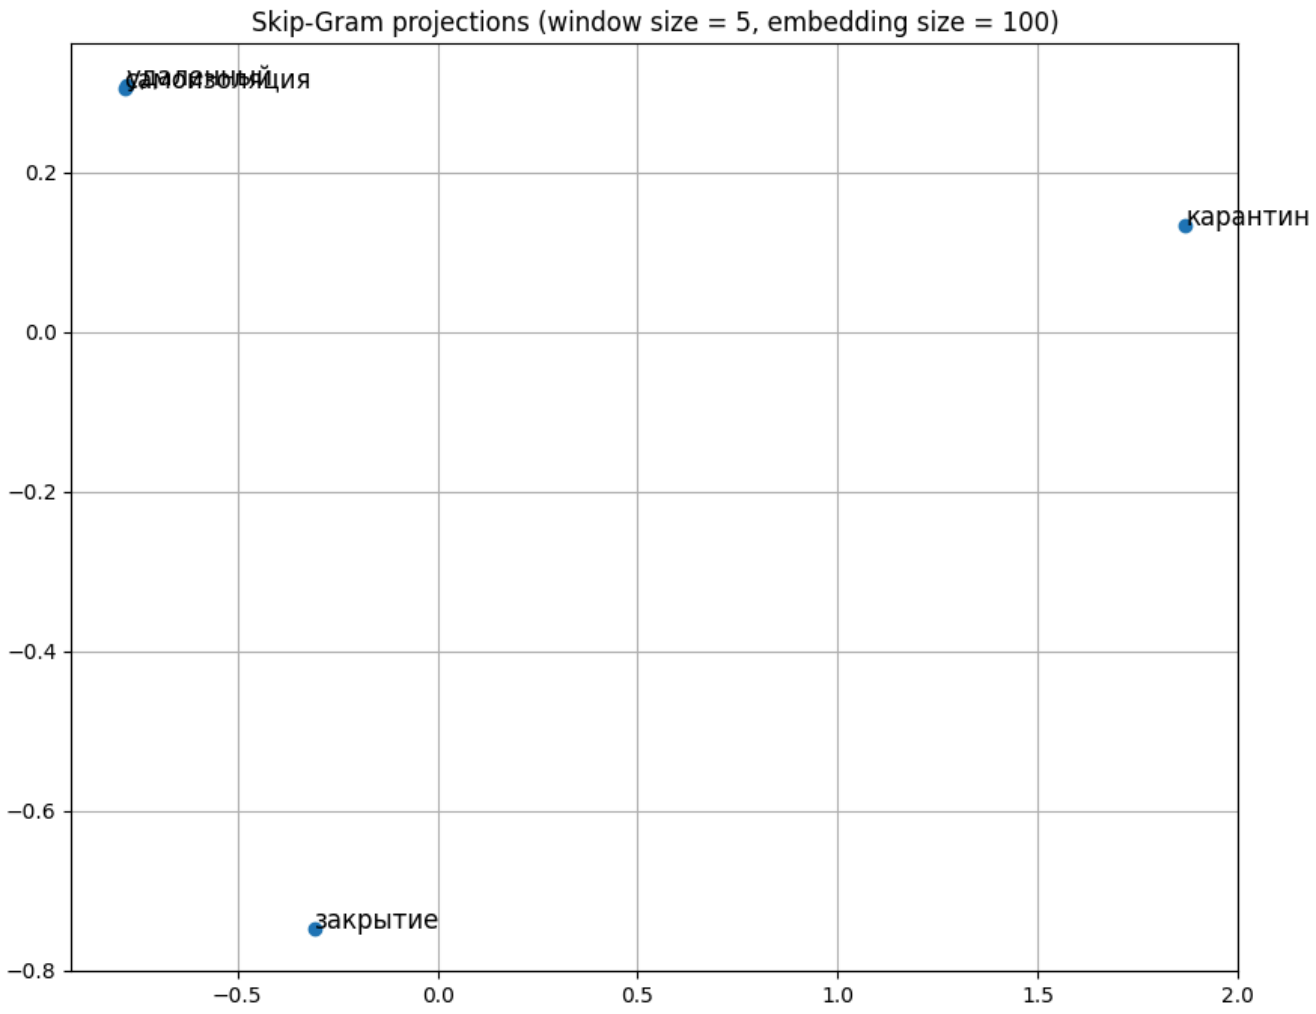

Гиперпараметры Skim-Gram: window size = 5, embedding size = 200
Урезанный датасет для Skip-Gram: 990620 пар
Epoch 1, Loss: 0.8132

Среднее сходство между словами ['карантин', 'самоизоляция', 'удаленный', 'закрытие']:
0.0196
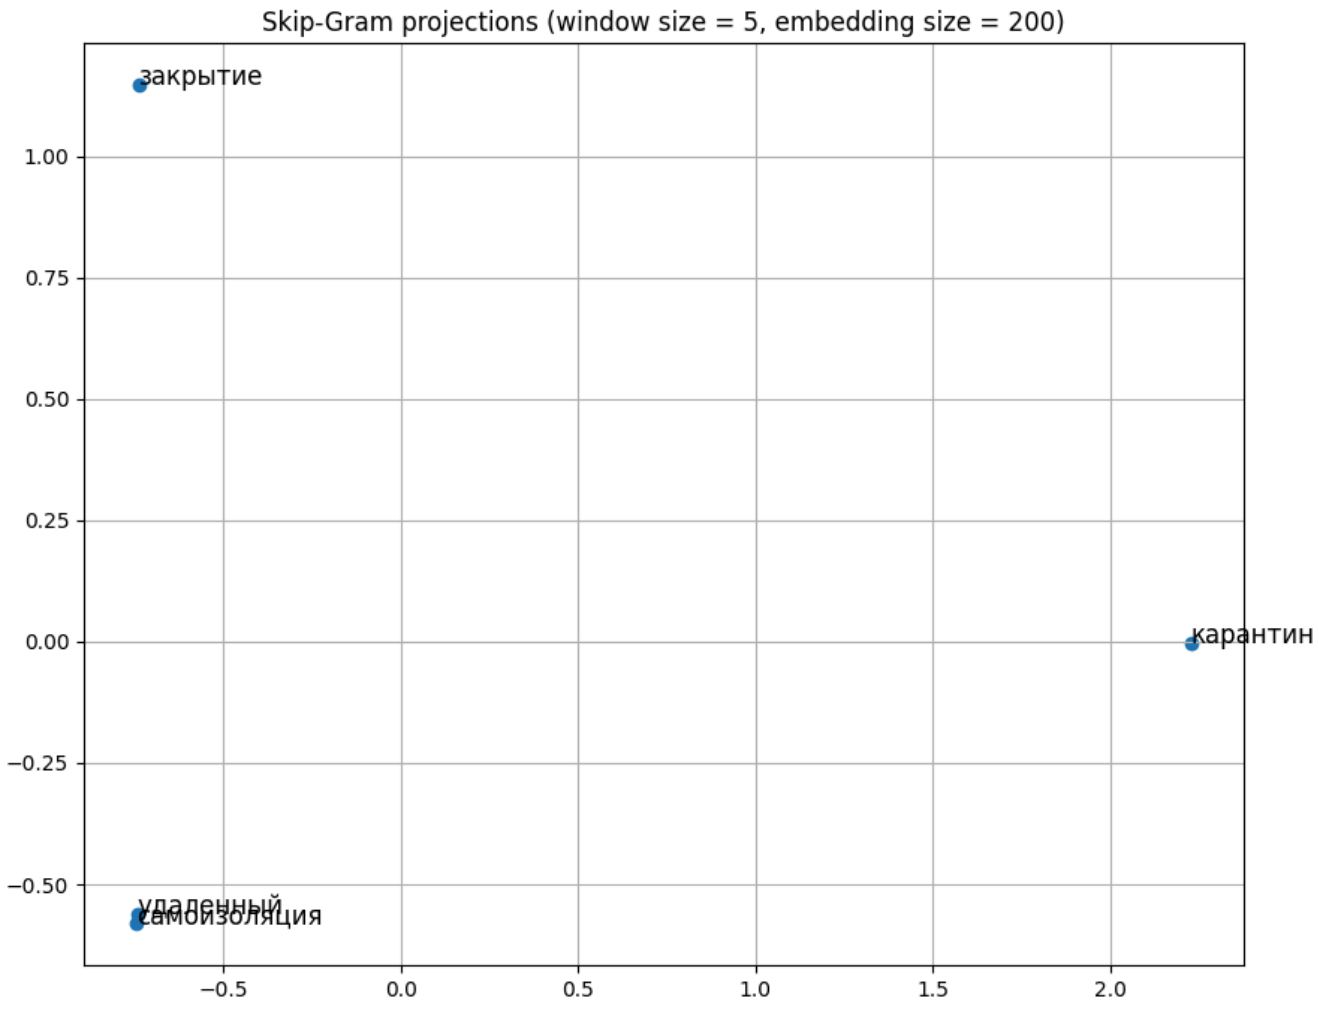
Визуализация эмбеддингов: